

Neuro-Symbolic AI 기반 다크패턴 탐지 프로젝트

지도 교수 : 조민수 교수님

팀원 : 정수진, 박현우, 박소영, 오민진, 박제인, 정유빈




구글 학장자 다운받기



광운대학교
KwangWoon University


01. 다크패턴(Dark Pattern)이란?

디지털 서비스 내의 표현 방식을 통해
의도하지 않은 행동을 하도록 유도하여 선택을 왜곡시키는 설계 방식




02. Neuro-Symbolic AI란?

딥러닝(Neural Network)의 학습 능력과
기호적 인공지능(Symbolic AI)의 논리적 추론 능력을 결합한 인공지능 접근 방식



03. 프로젝트 요약




사용자가 탐지를 원하는 웹사이트에 접속하면, 확장 프로그램이 페이지 내 문장을 실시간으로 크롤링하고, 이를 NSAI 모델에 전달해 다크 패턴 여부를 자동으로 분석 및 시각화한다.

04. 사용자 리서치

설문 조사

온라인에서 일반 이용자 41명을 대상으로 설문조사를 진행하였다.
유형별 대표적인 피해 사례를 제시하고
이에 대한 실제 경험 여부의 비율을 분석하였다.




문제 정의 및 기획 의도

다크패턴은 서비스가 사용자보다 더 많은 정보와 설계 권한을 가진
정보의 비대칭성에서 비롯된다. 사용자의 인지 여부와 무관하게
주의 분산과 시간 압박 속에서 잘못된 선택을 하는 경우가 많기에,
다크패턴을 탐지해 이를 예방할 수 있는 프로젝트를 기획했다.


05. 데이터 수집 및 전처리

1 데이터 정제

선행 연구 기반 11k 쇼핑물 웹사이트 크롤링 데이터 사용
병합, 중복 제거, 데이터 증강(Template, Paraphrase, Contextual)을 통해 불균형 해결



2 세부 유형 라벨링



Prometheus란? LLM 응답의 정확성을 정량적으로 평가하는 평가 방식

LLM이 생성한 세부 유형 라벨링 결과를 정답 데이터와 함께 입력하여,
1~5점 단위로 '얼마나 정답에 가깝게 라벨링했는지' 평가한다.


06. 모델링 과정

1 ResGCN

- LLM 정량 평가 점수를 노드에 가중치로 활용하며, 적은 데이터에도 논리 구조 강화
- 기존 BERT(435 MB)에 비해, 약 500배 가벼운 ResGCN(0.85 MB)을 적용함으로써, 모델 크기를 99.8% 안정적으로 축소

2 Attention 활용 온톨로지 규칙 구성


Type 개별 규칙	Attention이 Type 분류 시 가장 주목한 토큰 집합을 rule로 추출
Predicate 개별 규칙	문장의 행위 기반 Predicate 분류 시, Attention에서 가장 주목한 토큰 집합 추출
Type ↔ Predicate 관계 규칙	대표 토큰 마스크링 시, 예측 확률 변동이 ±0.1 이상인 경우 관계 규칙으로 채택



3 DeepProbLog

DeepProbLog는 Neural Network와 Logic Program을 통합하는 프레임워크로,
본 프로젝트에서는 ResGCN의 출력을 Neural predicate로 활용하고,
Attention 기반 규칙을 pl 형식으로 연결하여 확률적 추론 모델을 구성했다.


07. 확장 프로그램 개발



세부 유형 확인
실제 탐지된 문장과 다크패턴의 유형/세부 유형을 모두 알려준다


다크패턴 가능성
예측 확률에 따른 3가지(높음, 중간, 낮음) 분류

다크패턴 위치 보기
해당 버튼을 클릭하면, 크롬 웹페이지 내에서 탐지된 문장을 찾아 구분하기 쉽도록 강조



확장프로그램 실행 화면

08. 기대 효과



1 기술적 효과

Attention 기반 규칙 해석을 통해 다크패턴의 판단 근거를 시각화
및 서비스 전환의 설계 윤리성 및 법적 대응 가능성을 강화할 수 있다.

2 산업적 효과

웹, 앱 내 사용자 경험을 사전에 점검하여 소비자 오인 유발 UI를 예방
및 브랜드의 디지털 신뢰도 및 UX 품질 지표를 향상시킬 수 있다.

3 사회적 효과

사용자의 합리적 선택을 돕고, 정보 비대칭·시간 낭비·감정적 불쾌감을 줄여 디지털 소비 환경의 공정성을 높일 수 있다.